

IA PARA DEVS

DESENVOLVIMENTO DE ML NA CLOUD

AULA 02

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	9
REFERÊNCIAS	10

EMSE

O QUE VEM POR AÍ?

Os modelos de aprendizado de máquina são ferramentas poderosas para resolver problemas complexos. Embora seja possível treinar modelos de aprendizado de máquina localmente, existem algumas limitações quanto a essa abordagem. E se a energia elétrica acabar? E se os recursos computacionais, como capacidade de processamento, memória e armazenamento não forem suficientes? E se quisermos escalar os recursos para acelerar o treinamento? E se quisermos disponibilizar o nosso modelo on-line para outras pessoas utilizarem?

Nesta aula, iremos, então, resolver alguns destes problemas utilizando as ferramentas do Azure Machine Learning Studio para treinar e implantar um modelo de aprendizado de máquina utilizando ferramentas de computação em nuvem.

HANDS ON

Vamos implementar um modelo de aprendizado de máquina utilizando ferramentas de computação em nuvem da Azure. Como exemplo, trabalharemos com a tarefa de análise de sentimentos. Nesta tarefa, temos como entrada um texto e o nosso objetivo é treinar um modelo que nos indicará se um dado texto está associado a um sentimento negativo, neutro ou positivo.

Na primeira etapa, faremos um treinamento simples utilizando apenas uma máquina virtual dentro do Azure Machine Learning Studio.

Após isso, treinaremos o mesmo modelo, porém, desta vez, integrando com as ferramentas disponíveis dentro do Azure Machine Learning Studio. Por meio destas ferramentas, nós carregaremos e gerenciaremos o conjunto de dados, registraremos e conduziremos tarefas de treinamento dos modelos, gerenciaremos os modelos treinados e, por fim, faremos a implantação e consumo do modelo treinado, tudo isso de forma integrada. Como última etapa, mostraremos como desalocar os recursos utilizados para evitar cobranças indesejadas.

Criando e Configurando Ambiente

Criando uma conta e acessando o Azure

Para acessarmos as ferramentas de aprendizado de máquina do Microsoft Azure, primeiramente precisamos criar uma conta. Para isso, acesse a página do [Azure](#) e clique no link para criar uma conta e siga os passos conforme mostramos na videoaula.

Além de criar e configurar o ambiente no Azure, acesse este [repositório](#) com os materiais para ter acesso aos materiais utilizados durante o hands on.

SAIBA MAIS

Até aqui, apresentamos como treinar um modelo de aprendizado de máquina utilizando os recursos da Azure. Nesta seção, vamos detalhar um pouco mais sobre estes recursos e, ao final, vamos fazer alguns paralelo de recursos entre outros dois importantes fornecedores de serviços de computação em nuvem: Google Cloud Platform (GCP) e Amazon Web Services (AWS).

Computação sem servidor

Na segunda etapa da aula utilizamos integrações com as ferramentas do Azure Machine Learning Studio para iniciar uma tarefa de treinamento do nosso modelo de aprendizagem de máquina. Porém, fica uma pergunta: como este modelo foi treinado? A resposta é: utilizando computação sem servidor (serverless).

A computação sem servidor é um modelo de execução de código que permite que os desenvolvedores e desenvolvedoras criem aplicativos sem se preocupar com a infraestrutura em que eles serão executados.

Com a computação sem servidor, o provedor de nuvem (Azure, AWS, Google Cloud etc.) é responsável por iniciar e parar dinamicamente a alocação de recursos de computação. A pessoa desenvolvedora paga apenas pelo tempo de execução do código, sem se preocupar com a infraestrutura utilizada. Dessa forma, o profissional de dados pode se concentrar no desenvolvimento de modelos de aprendizado de máquina e se preocupar menos com a infraestrutura necessária para treiná-los.

A alternativa computação sem servidor seria a computação em máquinas virtuais ou em clusters de computação.

Utilizar uma máquina virtual exige que o profissional de dados configure e gerencie uma máquina virtual, da mesma forma que criamos no exemplo apresentado uma máquina virtual para executar o notebook do experimento.

Um cluster de computação, por outro lado, é um conjunto de máquinas virtuais que podem ser configuradas para executar tarefas de computação em paralelo. A pessoa profissional de dados precisa configurar e gerenciar o cluster de computação, além de configurar o código para executar essas tarefas.

Ao utilizarmos a computação não precisamos nos preocupar em gerenciar a infraestrutura, pois o provedor de nuvem é responsável por iniciar e parar dinamicamente a alocação de recursos de computação. A única medida é configurar o código para executar as tarefas de treinamento do modelo.

No entanto, também existem algumas desvantagens em relação ao uso de computação sem servidor.

- **Gerenciamento:** embora a computação sem servidor possa simplificar o desenvolvimento, gerenciar vários serviços sem servidor se torna complexo, como por exemplo, disparar inúmeros experimentos de treinamento de modelos de aprendizagem de máquina.
- **Disponibilidade:** por se tratar de um recurso sob demanda, o tempo de inicialização da execução de uma computação sem servidor pode variar, o que pode levar a latências imprevisíveis.
- **Depuração do treinamento:** é mais desafiador depurar e monitorar aplicativos sem servidor, uma vez que não temos acesso a infraestrutura. Pode ser difícil identificar a origem de uma demora não esperada em um treinamento de um modelo, por exemplo.

Por fim, a computação sem servidor pode ter limitações em termos de recursos disponíveis (CPU, memória, armazenamento), o que pode impedir a execução de tarefas de computação que exigem maior capacidade.

Recursos de dados

No nosso experimento utilizamos como conjunto de dados um arquivo simples em formato csv. Apesar disso, o Azure Machine Learning permite tratar arquivos tabulares de maneira mais eficiente por meio dos “mltable”. Isso permite consolidar diversos arquivos com o mesmo esquema de colunas automaticamente na plataforma, além de definir regras de pré-processamento destes dados pela própria interface do Azure ML.

Por meio do “mltable” é possível fazer diversas transformações nos dados usando arquivos de configuração. Por meio destes arquivos de configuração nós podemos:

- Filtrar os dados de diversas formas.
- Selecionar apenas as colunas desejadas.

- Carregar amostras aleatórias.

Embora possamos fazer essas etapas dentro do código, trazer essas funcionalidades junto a um arquivo de configuração facilita a reprodutibilidade e manutenção do processo, uma vez que o código deixa de ser responsável por esse tipo de configuração. Logo se o nome das colunas dos dados muda, por exemplo, podemos tratar isso direto no arquivo de configuração em vez de ter que tratar isso dentro do código que realiza o treinamento do modelo. Se diversos códigos utilizam estes dados, pode ser uma grande tarefa gerenciar essas modificações.

Equivalência entre fornecedores de computação em nuvem

A computação em nuvem se tornou fundamental para o desenvolvimento de modelos de aprendizado de máquina, oferecendo uma variedade de recursos e serviços. A seguir, destacamos alguns dos principais provedores e suas ofertas específicas para esse campo.

Amazon Web Services (AWS)

Amazon SageMaker: é um serviço completo de Machine Learning oferecido pela AWS. Ele engloba desde a preparação dos dados até a implantação do modelo, simplificando todo o processo. SageMaker oferece integração com diversos frameworks populares, como TensorFlow e PyTorch.

Instâncias otimizadas para ML: a AWS disponibiliza instâncias EC2 especializadas para cargas de trabalho de Machine Learning, como as instâncias Inf1, que são equipadas com aceleradores de inferência.

Google Cloud Platform

Google Cloud AI: oferece uma ampla gama de APIs e serviços para tarefas específicas de ML, como visão computacional, processamento de linguagem natural, entre outros. Além disso, fornece suporte para frameworks populares como TensorFlow, PyTorch e scikit-learn.

Recursos de Processamento: a Google Cloud oferece unidades de processamento especializadas para acelerar tanto treinamentos quanto inferências de modelos de ML, como as GPUs e TPUs.

IBM Cloud

IBM Watson: oferece serviços como Watson Studio, uma plataforma de colaboração para a preparação de dados e criação de modelos, e Watson Machine Learning, que permite a implantação e gerenciamento de modelos.

IBM Watson AutoAI: simplifica a criação de modelos de ML com automação desde a preparação dos dados até a seleção do modelo mais adequado, facilitando para usuários com menos experiência em Machine Learning.

A seguir, apresentamos uma tabela com as equivalências dos serviços de cada fornecedor:

Recurso/Serviço	Microsoft Azure	AWS (Amazon Web Services)	Google Cloud Platform	IBM Cloud
Serviços de ML	Azure Machine Learning	Amazon SageMaker	Google Cloud AI	IBM Watson
Frameworks Suportados	TensorFlow, PyTorch, ONNX	TensorFlow, PyTorch, MXNet	TensorFlow, PyTorch, scikit-learn	TensorFlow, PyTorch, Keras
Recursos de Processamento	VMs de série N	Instâncias EC2 Inf1	GPUs, TPUs	GPUs, CPUs otimizadas
Ferramentas de AutoML	Azure AutoML	Amazon SageMaker Autopilot	Google AutoML	IBM Watson AutoAI

Tabela 1 – Tabela de equivalência
Fonte: Elaborado pelo autor (2024)

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, foi apresentado como criar um modelo de aprendizado de máquina utilizando os recursos de computação em nuvem da Azure. Foi apresentado também, como configurar o ambiente de desenvolvimento, criação de máquina virtual e execução de um jupyter notebook, que serviu de interface para os nossos desenvolvimentos.

O primeiro experimento consistiu em criar um modelo simples, sem qualquer integração com as ferramentas de nuvem. Esse exemplo teve como objetivo mostrar as limitações de trabalhar o ciclo de vida de um sistema de aprendizado de máquina sem outras ferramentas de suporte.

Em seguida foi realizado outro experimento, desta vez apresentando como criar um modelo de aprendizado de máquina integrado com as ferramentas, facilitando o gerenciamento do sistema como um todo. Isso permitiu implantarmos facilmente o modelo treinado para que ele pudesse receber requisições e enviar respostas de qualquer lugar com acesso a internet. Por fim, foi brevemente apresentado como desalocar os recursos utilizados.

REFERÊNCIAS

AWS. **Instâncias Inf1 do Amazon EC2**. 2023. Disponível em: <<https://aws.amazon.com/pt/ec2/instance-types/inf1/>>. Acesso em: 21 mar. 2024.

Google Cloud. **Cloud Tensor Processing Units (Cloud TPUs)**. 2023. Disponível em: <<https://cloud.google.com/tpu/docs/tpus>>. Acesso em: 21 mar. 2024.

IBM. **Acelerando a IA e o gerenciamento do ciclo de vida de modelos**. 2023. Disponível em: <<https://www.ibm.com/br-pt/products/watson-studio/autoai>>. Acesso em: 21 mar. 2024.

IBM. **Watson Machine Learning**. 2023. Disponível em: <<https://cloud.ibm.com/catalog/services/watson-machine-learning#about>>. Acesso em: 21 mar. 2024.

Microsoft. **Create an Azure Machine Learning compute cluster**. 2023. Disponível em: <<https://learn.microsoft.com/en-us/azure/machine-learning/how-to-create-attach-compute-cluster>>. Acesso em: 21 mar. 2024.

Microsoft. **Model training on serverless compute**. 2023. Disponível em: <<https://learn.microsoft.com/en-us/azure/machine-learning/how-to-use-serverless-compute>>. Acesso em: 21 mar. 2024.

Microsoft. **Working with tables in Azure Machine Learning**. 2023. Disponível em: <<https://learn.microsoft.com/en-us/azure/machine-learning/how-to-mltable>>. Acesso em: 21 mar. 2024.

PALAVRAS-CHAVE

Aprendizado de Máquina. Computação em Nuvem. Computação Serverless.

EMAP



POSTECH